



МУРМАНСКИЙ
АРКТИЧЕСКИЙ
УНИВЕРСИТЕТ
АПАТИТСКИЙ ФИЛИАЛ

РАЗРАБОТКА ИНФОРМАЦИОННОЙ СИСТЕМЫ ДЛЯ ИССЛЕДОВАТЕЛЬСКОГО ПОИСКА В МАССИВАХ СТРУКТУРИРОВАННЫХ ДАННЫХ С ПОМОЩЬЮ БОЛЬШИХ ЯЗЫКОВЫХ МОДЕЛЕЙ

Выполнил обучающийся

Фигуркин Даниил Сергеевич

Направление подготовки 09.03.02 Информационные системы и технологии

Направленность (профиль) Программно-аппаратные комплексы

Очная форма обучения

Группа 4БИСИТ-ПАК_АФ

Научный руководитель:

Федоров Андрей Михайлович – канд. техн. наук

АКТУАЛЬНОСТЬ, ПРОБЛЕМА И ЦЕЛЬ



Институт информатики и
математического моделирования
им. В.А. Путилова



МУРМАНСКИЙ
АРКТИЧЕСКИЙ
УНИВЕРСИТЕТ
АПАТИТСКИЙ ФИЛИАЛ

Актуальность:

Существует множество старых Pascal/Delphi-проектов с большим объёмом кода, нелинейной структурой и устаревшей документацией.

Проблема:

Сопровождение этих проектов осложнено. Разработчик часто вручную выявляет логику и структуру.

Цель:

создать систему, которая преобразует Pascal/Delphi-кодovou базу в удобное для поиска и навигации представление.

Система не заменяет IDE, а добавляет промежуточный навигационно-поисковый слой между кодом и разработчиком

ОБЪЕКТ, ПРЕДМЕТ И ЗАДАЧИ



Институт информатики и
математического моделирования
им. В.А. Путилова



МУРМАНСКИЙ
АРКТИЧЕСКИЙ
УНИВЕРСИТЕТ
АПАТИТСКИЙ ФИЛИАЛ

Объект:

массивы структурированных данных,
представленные кодовыми базами
Pascal/Delphi-проектов.

Предмет:

подходы к извлечению, представлению и
поиску информации в кодовых базах
Pascal/Delphi-проектов.

Задачи:

- рассмотреть код как структурированные данные;
- сравнить подходы к поиску в программном коде;
- определить требования к представлению для человека, алгоритма и LLM;
- выбрать технологии извлечения, wiki-представления, RAG-поиска и агентной интеграции;
- разработать архитектуру и проверить работу системы.

ТЕОРИЯ И ТРЕБОВАНИЯ К СИСТЕМЕ



Институт информатики и
математического моделирования
им. В.А. Путилова



МУРМАНСКИЙ
АРКТИЧЕСКИЙ
УНИВЕРСИТЕТ
АПАТИТСКИЙ ФИЛИАЛ

Код как структура

Для анализа важны не только строки, но и программные сущности.

Исследовательский поиск

разработчик может не знать точное имя объекта, а знать лишь функционал, который ему нужно найти.

AI-обогащение

Процесс обогащения документации комментариями

LLM + RAG

Большая языковая модель не содержит данных о кодовой базе, но может оперативно получать нужные для ответа сведения из RAG.

Обязательные

- Pascal/Delphi-кодовая база
- семантический поиск
- интеграция с AI-агентом
- доступ к исходному коду
- разные представления для акторов

Дополнительные

- локальная работа
- логирование процессов
- отладочные команды
- проверяемость источников
- легко-воспроизводимая архитектура


АРХИТЕКТУРА РЕШЕНИЯ



Институт информатики и
математического моделирования
им. В.А. Путилова



МУРМАНСКИЙ
АРКТИЧЕСКИЙ
УНИВЕРСИТЕТ
АПАТИТСКИЙ ФИЛИАЛ



Входные данные

Кодовая база Pascal/Delphi

Выходные данные

Obsidian-совместимая wiki
OpenCode-агент с дополнительными MCP серверами.


СТРУКТУРА ПРОЕКТА



Институт информатики и
математического моделирования
им. В.А. Путилова



МУРМАНСКИЙ
АРКТИЧЕСКИЙ
УНИВЕРСИТЕТ
АПАТИТСКИЙ ФИЛИАЛ



дерево проекта finalversion

Четыре основные области проекта

- 1) .config — локальные настройки
- 2) code — генератор, pipeline, wrapper
- 3) data — входы, wiki, кэш, логи
- 4) tools — внешние компоненты

Причина компоновки

компоненты не смешиваются. собственная разработка, данные выполнения и внешние инструменты отделены друг от друга.

разработка информационной системы для исследовательского поиска в массивах структурированных данных с помощью больших языковых моделей


ГЕНЕРАЦИЯ WIKI-ДОКУМЕНТАЦИИ



Институт информатики и
математического моделирования
им. В.А. Путилова




МУРМАНСКИЙ
АРКТИЧЕСКИЙ
УНИВЕРСИТЕТ
АПАТИТСКИЙ ФИЛИАЛ



логика работы скрипта генерации wiki

разработка информационной системы для исследовательского поиска в массивах структурированных данных с помощью больших языковых моделей

минуты



Оценка времени подготовки для
проекта объёмом 98 КБ кода с 11%
изначальных комментариев

RAG И СЕМАНТИЧЕСКИЙ ПОИСК



Институт информатики и
математического моделирования
им. В.А. Путилова



**МУРМАНСКИЙ
АРКТИЧЕСКИЙ
УНИВЕРСИТЕТ**
АПАТИТСКИЙ ФИЛИАЛ

Источник

Wiki-документация:
страницы unit и классов

преобразователь

markdown-rag-mcp делит Markdown на фрагменты, строит embedding-векторы и сохраняет их в Milvus.

Поиск

Векторизованный запрос пользователя сравнивается с векторами чанков.

GpProperty

Unit: GpProperty

Исходник: `src/GpProperty.pas`

RAG-поисковые ключи

- * kind: unit
- * id: GpProperty
- * source_path: src/GpProperty.pas
- * routines: CreateGpProperty, CreateGpProperty, GetFloatProp, SetFloatProp, GetWideStrProp, SetWideStrProp, SetToString, StringToSet

Общее описание

GpProperty

Назначение: Упрощённый доступ к опубликованным (published) свойствам объектов Delphi.

[illegible]

фрагмент страницы wiki с RAG-ключами

контрольный поиск после индексации

разработка информационной системы для исследовательского поиска в массивах структурированных данных с помощью больших языковых моделей

АГЕНТНАЯ ЧАСТЬ




Институт информатики и
математического моделирования
им. В.А. Путилова



МУРМАНСКИЙ
АРКТИЧЕСКИЙ
УНИВЕРСИТЕТ
АПАТИТСКИЙ ФИЛИАЛ

Зачем wrapper

markdown-rag-mcp
используется как backend.
Wrapper предоставляет поиск
как MCP-инструмент для
OpenCode.



Инструменты

markdown_rag_ping
markdown_rag_warmup
markdown_rag_search
markdown_rag_reload_engine

Сценарий работы агента

RAG даёт навигационный контекст; при
вопросах о реализации результат уточняется
по исходным файлам с помощью pasls или
прямого чтения.

ДЕМОНСТРАЦИЯ РАБОТЫ СИСТЕМЫ




Институт информатики и
математического моделирования
им. В.А. Путилова



МУРМАНСКИЙ
АРКТИЧЕСКИЙ
УНИВЕРСИТЕТ
АПАТИТСКИЙ ФИЛИАЛ

```
[pipeline] PROJECT_ROOT: D:/works/yueba/exp/finalversion/data/input_project/src
[pipeline] WIKI_DIR: D:/works/yueba/exp/finalversion/data/wiki_out/current
[pipeline] Запускаю/проверяю Milvus через Docker Compose
time="2026-05-23T15:23:44+03:00" level="warning" msg="D:\\works\\yueba\\exp\\finalversion\\tools\\markdown-rag-mcp\\docker\\docker-compose.yml: the attribute 'version' is obsolete, it will be ignored, please remove it to avoid potential confusion"
[+] up 8/8
  ✓ network docker_milvus      Created      0.1s
  ✓ volume docker_milvus       Created      0.0s
  ✓ volume docker_etcd         Created      0.0s
  ✓ volume docker_minio        Created      0.0s
  ✓ container milvus-etcd       Started      0.6s
  ✓ container milvus-minio      Started      0.7s
  ✓ container milvus-standalone Started      0.8s
  ✓ container milvus-attu       Started      1.0s
[pipeline] Milvus rotos: milvus-standalone (healthy)
[pipeline] Генерирую Markdown wiki
[pipeline] WIKI_DIR: D:/works/yueba/exp/finalversion/data/wiki_out/current
[pipeline] log wiki: D:/works/yueba/exp/finalversion/data/logs/wiki-build-2026-05-23-15-23-52.log
CONFIG_FILES: D:/works/yueba/exp/finalversion/.config/ai-descr.local.conf
CONFIG_LOADED: true
PROJECT_ROOT: D:/works/yueba/exp/finalversion/data/input_project/src
PASDOC_PROG: D:/works/yueba/exp/finalversion/tools/pasdoc/bin/pasdoc.exe
XMLSTARLET_BIN: D:/works/yueba/exp/finalversion/tools/xmlstarlet-1.6.1/xml.exe
JOL_BIN: D:/works/yueba/exp/finalversion/tools/bin/jq.exe
EXP_ROOT: /tmp/pasdoc_wiki_2026-05-23-15-23-52_wdk1b
DOC_DIR: /tmp/pasdoc_wiki_2026-05-23-15-23-52_wdk1b/docs_tmp
STAGE_DIR: /tmp/pasdoc_wiki_2026-05-23-15-23-52_wdk1b/stage
WIKI_DIR: D:/works/yueba/exp/finalversion/data/wiki_out/current
AI_PROVIDER: openrouter
AI_URL: https://openrouter.ai/api/v1/chat/completions
AI_MODEL: poolside/rogue-a-1-free
AI_ENRICH_UNITS: true
AI_ENRICH_CLASSES: true
AI_ENRICH_METHODS: false
CACHE_DIR: D:/works/yueba/exp/finalversion/data/cache/ai-descriptions
[1] Обработка: D:/works/yueba/exp/finalversion/data/input_project/src/GpLockFreeQueue.pas
AI generate: GpLockFreeQueue/class/TGpLockFreeQueue
OK: GpLockFreeQueue
[2] Обработка: D:/works/yueba/exp/finalversion/data/input_project/src/GpProperty.pas
AI generate: GpProperty/unit/GpProperty
OK: GpProperty
[3] Обработка: D:/works/yueba/exp/finalversion/data/input_project/src/GpStringHash.pas
AI generate: GpStringHash/class/TGpStringHashKV
AI generate: GpStringHash/class/TGpStringHashEnumerator
AI generate: GpStringHash/class/TGpStringHash
AI generate: GpStringHash/class/TGpStringObjectHashKV
AI generate: GpStringHash/class/TGpStringObjectHashEnumerator
AI generate: GpStringHash/class/TGpStringObjectHash
AI generate: GpStringHash/class/TGpStringInterfaceHashKV
AI generate: GpStringHash/class/TGpStringInterfaceHashEnumerator
AI generate: GpStringHash/class/TGpStringTableKV
AI generate: GpStringHash/class/TGpStringTableEnumerator
AI generate: GpStringHash/class/TGpStringTable
AI generate: GpStringHash/class/TGpStringObjectHashKV
AI generate: GpStringHash/class/TGpStringObjectHash
AI generate: GpStringHash/class/TGpStringDictionaryKV
AI generate: GpStringHash/class/TGpStringDictionaryEnumerator
AI generate: GpStringHash/class/TGpStringHashKV
```



старт сборки wiki и индекса

Markdown-wiki в Obsidian

- Классы для хэширования строк:**
 - TGpStringHash** – базовый класс, хранящий строковые ключи через хэштеблицы.
 - TGpStringTableKV** – реализация хэш-таблицы для хранения пар ключ-значение.
- Ключевые методы:**
 - HashOf** – преобразует строку в числовое хэш-значение.
 - GetGoodHashSize** – определяет оптимальный размер таблицы для минимизации коллизий.
 - GetKey/SetKey** – получение/установка строкового ключа.
- Итераторы:**
 - TGpStringHashEnumerator** – позволяет перебирать элементы таблицы по ключам.
- Ассоциативные структуры:**
 - TGpStringDictionaryKV** – упрощенный интерфейс для работы с ключами через свойства Delphi-объектов.

Для точного понимания реализации стоит изучить файл **src/GpStringHash.pas**, где определены эти классы и методы. Хотите, я покажу определение какого-либо конкретного символа из этого файла?

ответ OpenCode-агента на вопрос по кодовой базе

разработка информационной системы для исследовательского поиска в массивах структурированных данных с помощью больших языковых моделей

Ограничения

- зависимость от PasDoc
- семантическая близость не равна точной реализации
- результат зависит от разбиения Markdown
- AI-обогащение увеличивает время подготовки
- ориентация на поиск, а не на активное редактирование
- требование прогревочных действий от пользователя

Направления развития

- валидация SimpleXML и дополнительный мини-парсер
- улучшение структуры wiki под индексацию
- гибридные инструменты поиска
- точечное обновление wiki и индекса
- переход к графовой базе или базе знаний
- автоматизация прогревов

ЗАКЛЮЧЕНИЕ



Институт информатики и
математического моделирования
им. В.А. Путилова



МУРМАНСКИЙ
АРКТИЧЕСКИЙ
УНИВЕРСИТЕТ
АПАТИТСКИЙ ФИЛИАЛ

Результат работы

Создана локальная информационная система, формирующая навигационно-поисковый слой над Pascal/Delphi-кодовой базой.

Работоспособность

Тестирование показало, что система снижает сложность первичного изучения незнакомого Pascal/Delphi-проекта

Поставленная практическая задача выполнена: цепочка подготовки и использования данных работает на основном сценарии.